Rapport de synthèse académique

Analyse multi-paradigme de 29 algorithmes de Machine Learning

Auteur	Yacoubi Hiba
Parcours	S7 — ENCG Settat
Année universitaire	2026–2027
Variante	Variante C (graine aléatoire : 42)
Jeux de données réels	Diabetes, Breast Cancer Wisconsin, Wine
Environnement simulé	CliffWalking-v1

1. Introduction et cadre méthodologique

Ce rapport présente une étude comparative systématique de 29 algorithmes fondamentaux d'apprentissage automatique, regroupés en cinq grandes familles : la régression, la classification, le clustering, la réduction de dimensionnalité (avec détection d'anomalies) et l'apprentissage par renforcement.

L'objectif méthodologique est d'éviter le piège d'une sélection naïve de modèles, fondée sur la seule mémorisation empirique, et de mettre en œuvre un protocole de validation rigoureux. Aucune décision d'ajustement ou d'arrêt n'a exploité les données de test, ce qui préserve l'étanchéité de l'évaluation finale. La reproductibilité stricte est assurée par une graine aléatoire globale fixée à 42.

2. Réglages testés et sensibilité des modèles

Le tableau ci-dessous récapitule les configurations d'hyperparamètres testées, la justification de chaque modification et son effet sur les métriques de généralisation mesurées sur l'échantillon de test.

N°	Algorithme	Valeur initiale	Valeur modifiée	Métrique de test	Impact et justification
2	Ridge	α = 12,0	α = 2,0	R^2 = 0,486 MAE = 41,48	La baisse de la pénalité L2 accroît légèrement la variance mais réduit le biais de contraction ; le modèle s'adapte mieux aux composantes de variance moyenne de Diabetes.
3	Lasso	α = 1,0	α = 0,5	R^2 = 0,491 MAE = 41,42	Conserve 9 variables actives sur 10. L'allègement de la pénalité L1 limite le sous-ajustement des coefficients importants.
4	Polynôme	Degré 2, α = 100	Degré 2, α = 50,0	R^2 = 0,506 MAE = 41,05	Meilleure performance globale sur Diabetes : les interactions d'ordre 2 associées à une régularisation Ridge modérée offrent le meilleur compromis.
5	Arbre (rég.)	max_depth = 3	max_depth = 5	R^2 = 0,372 MAE = 47,01	Effondrement de la performance : une profondeur excessive sur un petit jeu de données fragmente l'espace et mémorise le bruit.

N°	Algorithme	Valeur initiale	Valeur modifiée	Métrique de test	Impact et justification
6	Forêt (rég.)	n_estimators = 60	n_estimators = 150	R^2 = 0,476 MAE = 42,91	Stabilisation de la variance par rapport à l'arbre unique profond ; la loi des grands nombres lisse la surface prédictive.
7	Gradient Boosting (rég.)	max_iter = 100	max_iter = 40	R^2 = 0,468 MAE = 43,02	Un arrêt précoce limite le surapprentissage séquentiel et réduit de 60 % le coût de calcul.
8	Régression logistique	C = 0,5	C = 0,1	F1 = 0,983	Une régularisation L2 accrue (C faible) restreint les poids et lisse la frontière sigmoïde sur Breast Cancer.
9	KNN	n_neighbors = 7	n_neighbors = 3	F1 = 0,978	Un voisinage très local capte les sous-densités propres aux tumeurs, mais reste très sensible au bruit.
10	Naive Bayes	var_smoothing = 1e-9	var_smoothing = 1e-5	F1 = 0,935	Un lissage de variance plus fort évite les probabilités conditionnelles quasi nulles sur les distributions à queue lourde.
11	Arbre (cls.)	max_depth = 3	max_depth = 6	F1 = 0,931	Le sur-partitionnement orthogonal réduit le biais d'entraînement mais dégrade nettement la généralisation.
12	Forêt (cls.)	max_features = 'log2'	max_features = 'sqrt'	F1 = 0,967	Évaluer davantage de variables par nœud accroît la corrélation entre arbres, mais stabilise le vote.
13	SVM	Noyau linéaire	Noyau RBF, C = 1,0	F1 = 0,983	Projection non linéaire robuste dans un espace de Hilbert, adaptée aux courbures complexes des données cliniques.
14	Gradient Boosting (cls.)	max_iter = 65	max_iter = 30	F1 = 0,967	L'arrêt précoce contrôle la dérive du gradient sur les points difficiles sans perte d'efficacité.
15	AdaBoost	learning_rate = 0,6	learning_rate = 0,2	F1 = 0,973	Un apprentissage plus lent compense la faible profondeur des apprenants et réduit la sensibilité au bruit.
16	XGBoost	max_depth = 2	max_depth = 4	F1 = 0,972	Autorise des interactions d'ordre 4, tout en restant encadré par les pénalités de complexité internes (L1/L2).
17	K-means	k = 3	k = 2	Silhouette = 0,259	Fusionne artificiellement deux sous-populations distinctes du jeu Wine et augmente fortement l'inertie intra-classe.
18	CAH	linkage = 'complete'	linkage = 'ward'	Silhouette = 0,277	Ward minimise l'accroissement de la variance intra-groupe et produit des clusters sphériques et homogènes.
19	DBSCAN	eps = 2,5	eps = 1,8	9 groupes 103 points de bruit	Le rétrécissement du rayon rompt la connectivité de densité ; les points périphériques sont classés comme bruit.
20	GMM	covariance = 'diag'	covariance = 'full'	Silhouette = 0,285	Des covariances non contraintes permettent des ellipses obliques adaptées aux corrélations entre variables.

Tableau 1 — Synthèse des expérimentations (N° = numéro de l'algorithme dans l'étude).

3. Analyse de la sensibilité aux hyperparamètres

3.1 Mécanismes de régularisation (modèles linéaires)

Les expériences sur Diabetes mettent en évidence la dualité entre les pénalités L2 (Ridge) et L1 (Lasso). Dans la régression Ridge, l'augmentation de α impose une contrainte quadratique sphérique qui contracte l'ensemble des coefficients de façon homogène vers zéro, sans jamais les annuler. Toutes les variables explicatives conservent ainsi une contribution, et la colinéarité est atténuée.

À l'inverse, la contrainte L1 du Lasso a la forme d'un losange dont les sommets coïncident avec les axes de coordonnées : les coefficients des variables les moins contributives sont annulés strictement, ce qui produit un modèle parcimonieux. Avec $\alpha = 0{,}5$, l'un des 10 descripteurs de Diabetes est entièrement supprimé : le Lasso joue alors le rôle d'algorithme de sélection automatique de variables.

3.2 Complexité structurelle des arbres et robustesse des ensembles

Un arbre de décision isolé, qu'il soit de régression ou de classification, présente un biais faible mais une variance très élevée. Lorsque `max_depth` passe de 3 à 5 ou 6, l'algorithme découpe l'espace d'entrée en hyper-rectangles de plus en plus étroits et capte des fluctuations propres à l'échantillon d'entraînement. Cela se traduit, sur Diabetes, par une chute marquée du R^2 de test (0,372).

Les méthodes d'ensemble contournent ce problème de deux manières distinctes :

- **Bagging (Random Forest).** Plusieurs arbres profonds sont entraînés indépendamment sur des échantillons bootstrap, avec un tirage aléatoire des variables de coupure (`max_features = 'sqrt'`). Les erreurs individuelles, peu corrélées, se compensent lors de la moyenne (ou du vote majoritaire), ce qui réduit fortement la variance globale sans dégrader le biais.
- **Boosting (Gradient Boosting, XGBoost, AdaBoost).** Le processus est séquentiel : chaque arbre ajouté, peu profond (faible variance, biais élevé), se concentre sur l'erreur résiduelle du modèle courant (gradient négatif de la perte). Cette approche réduit le biais de façon ciblée.

4. Analyse comparative des agents de renforcement

L'évaluation sur l'environnement de référence CliffWalking-v1 met en évidence la différence de philosophie entre le Q-learning (hors-politique, *off-policy*) et SARSA (sur-politique, *on-policy*). Leurs règles de mise à jour s'écrivent :

$$\textit{Q-learning :}\quad Q(s,a) \leftarrow Q(s,a) + \alpha\,[\,R + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)\,]$$

$$\textit{SARSA :}\quad Q(s,a) \leftarrow Q(s,a) + \alpha\,[\,R + \gamma \cdot Q(s',a') - Q(s,a)\,]$$

4.1 Comportement face au risque

- **Q-learning (optimiste).** La mise à jour utilise l'opérateur max sur a' : l'agent suppose qu'il choisira toujours la meilleure action à l'étape suivante. Il apprend donc la trajectoire la plus courte vers l'état terminal, en longeant directement la falaise. Pendant l'apprentissage, toutefois, l'exploration ε-greedy est maintenue à $\varepsilon \geq 0{,}08$: l'agent effectue régulièrement des pas aléatoires et chute fréquemment (pénalité de −100). Sa valeur moyenne de table Q s'établit à −11,23.
- **SARSA (prudent).** La mise à jour utilise l'action a' réellement choisie sous la politique exploratoire ε-greedy, et intègre donc le risque de chute lié aux actions aléatoires futures. L'algorithme dévalue systématiquement les états proches de la falaise et apprend un détour sécurisé, un large arc vers le haut. Cette trajectoire est plus longue en nombre de pas, mais elle élimine presque entièrement les chutes pendant l'apprentissage. La valeur moyenne de la table Q est de −22,89, ce qui traduit le coût d'une politique prudente et robuste.

5. Analyse des échecs et diagnostics

L'évaluation systématique des algorithmes révèle des scénarios d'échec liés à l'inadéquation entre les hypothèses des modèles et la structure réelle des données.

5.1 Diagnostic de mauvaise spécification linéaire

En régression classique, l'hypothèse de linéarité se vérifie en examinant les résidus $e_i = y_i - \hat{y}_i$ en fonction des valeurs prédites. Une structure non aléatoire signale une mauvaise spécification :

- une forme de parabole révèle des relations quadratiques non capturées, qui justifient le passage à une régression polynomiale de degré 2 ;
- une forme d'entonnoir (hétéroscédasticité) indique que la variance de l'erreur croît avec la cible, ce qui viole l'hypothèse de variance constante nécessaire à l'optimalité des moindres carrés.

5.2 Fléau de la dimension et hypothèses d'indépendance

- **KNN.** En haute dimension, les distances euclidiennes tendent à converger vers une valeur uniforme (perte de contraste). KNN peine alors à identifier des voisinages pertinents sans réduction de dimension préalable.
- **Naive Bayes.** L'hypothèse d'indépendance conditionnelle est irréaliste pour des variables fortement corrélées (par exemple la taille et le périmètre d'une tumeur dans Breast Cancer). L'information redondante est comptée plusieurs fois, ce qui pousse les probabilités a posteriori vers 0 ou 1 et dégrade la calibration des scores de confiance.

5.3 Instabilité d'initialisation et géométrie des clusters

K-means suppose des clusters sphériques, de tailles comparables et bien séparés. Sur Wine, dont les variables ont des échelles très hétérogènes, il ne restitue pas correctement les distributions réelles sans standardisation préalable. De plus, une initialisation aléatoire des centroïdes peut le piéger dans un minimum local, d'où l'intérêt de l'initialisation K-means++ ou d'un nombre d'initialisations `n_init` ≥ 10.

6. Limites éthiques, techniques et de reproductibilité

6.1 Reproductibilité stricte

Tous les algorithmes comportant une part d'aléa (séparation apprentissage/test, forêts aléatoires, projections non linéaires de type t-SNE ou UMAP, initialisation de K-means, politiques de renforcement) ont été exécutés avec une graine fixe (`random_state=42` ou `np.random.default_rng(42)`). Sans cette précaution, les variations de métriques d'une exécution à l'autre refléteraient le hasard de l'échantillonnage plutôt que l'effet réel des hyperparamètres.

6.2 Interdiction des comparaisons croisées

Il est scientifiquement incorrect de comparer directement des métriques relevant de tâches différentes :

- l'inertie intra-classe de K-means (somme des carrés des distances euclidiennes) n'a aucune commune mesure avec un score F1 ou une aire sous la courbe ROC (AUC) de classification ;
- le coefficient de détermination R^2 (sans unité) et la MAE (exprimée dans l'unité de la cible) décrivent deux aspects distincts de l'erreur d'un même modèle de régression.

6.3 Limites éthiques et sociétales

Les bonnes performances obtenues sur les bases cliniques (Breast Cancer et Diabetes) ne doivent pas masquer leurs limites opérationnelles :

- **Biais de sélection.** Ces jeux de données proviennent d'institutions précises et de périodes données ; ils ne reflètent pas la diversité génétique, démographique ou environnementale d'une population générale.
- **Limites diagnostiques.** Ces modèles statistiques sont des outils d'aide à la décision. Ils ne capturent pas les facteurs causaux complexes et ne sauraient remplacer l'expertise clinique ni la responsabilité éthique des professionnels de santé.

7. Conclusion

Cette étude confirme qu'aucun algorithme de Machine Learning n'est universellement supérieur aux autres (théorème du No Free Lunch). Le choix du modèle optimal dépend de la nature des données, de l'espace des caractéristiques (dimensionnalité, colinéarité) et des contraintes opérationnelles : interprétabilité d'une régression logistique face à la puissance prédictive, plus opaque, d'un XGBoost, ou encore sécurité d'un agent SARSA face à la falaise. La rigueur scientifique consiste à formuler clairement ces compromis et à appliquer un protocole d'évaluation étanche.